Código, implementación y discusión del problema de reconocimiento de dígitos

Integrantes del grupo:

- Juan David Bernal Vesga
- Oscar David Ordóñez Bolaños
- Juan Pablo Urrutia Parrado

A continuación, se muestra el paso a paso de la implementación de la solución, así como también la discusión de algunos resultados

Para ejecutar el cuaderno, se deben cumplir los siguientes requerimientos:

- Para este propósito se usa Python 3.10.0 como la versión de ejecución.
- Se deben tener las librerías instaladas, las cuales se encuentran en requirements.txt

Nota: para instalar las librerías, ejecutar en la terminal el siguiente comando: pip install -r requirements.txt

Dataset utilizado

Primeramente, se importan las librerías usadas para nuestro propósito, y se definen algunas funciones que sirven como herramientas para el análisis.

```
In [ ]: from keras.datasets import mnist
   import matplotlib.pyplot as plt
   import keras
   import numpy as np
```

El dataset que se usa es el mnist, el cual es un dataset de 60.000 entradas para entrenar y 10.000 para validar, como se muestra a continuación:

```
In [ ]: # Import dataset
   (x_train, y_train), (x_test, y_test) = mnist.load_data()

# Examine dataset shapes
print(x_train.shape, x_test.shape)
```

Visualizando algunos datos del dataset, vemos que son de tamaño 28x28 y están centrados, como se muestra a continuación:

```
In [ ]: fig, ((ax1, ax2), (ax3, ax4)) = plt.subplots(2, 2)
fig.suptitle('Dataset examples')
```

```
test = np.random.randint(0,10000)
ax1.imshow(x_test[test], cmap="binary")
ax1.title.set_text(y_test[test])
ax1.axis('off')
ax2.imshow(x_test[test+1], cmap="binary")
ax2.title.set_text(y_test[test+1])
ax2.axis('off')
ax3.imshow(x_test[test+2], cmap="binary")
ax3.title.set_text(y_test[test+2])
ax3.axis('off')
ax4.imshow(x_test[test+3], cmap="binary")
ax4.title.set_text(y_test[test+3])
ax4.axis('off');
```

Dataset examples

o

o

o

o

o

o

o

o

o

f

Ahora que se ha visto la estructura de los datos, los preparamos para ser usados por el modelo.

Creación del modelo inicial

Para trabajar con la API de Keras, se debe trabajar con imagenes de formato (M x N x 1). Se usa el método .reshape() para realizar esta acción. Finalmente, se normalizan los datos de la imagen dividiendo cada valor de píxel por 255 (ya que los valores RGB pueden variar de 0 a 255). Además, se necesita convertir la variable de verificación de int a categorías, ya que se trabajan con categorias del 0 al 9. Esto se puede lograr con la función to_categorical():

```
In []: # Reshape
    x_train = x_train.reshape(x_train.shape[0], 28, 28, 1)
    x_test = x_test.reshape(x_test.shape[0], 28, 28, 1)

# Parse and normalize
    x_train = x_train.astype('float32')
    x_test = x_test.astype('float32')
    x_train /= 255
    x_test /= 255

# Turn Y into categorical data
    y_train = keras.utils.to_categorical(y_train, 10)
    y_test = keras.utils.to_categorical(y_test, 10)
```

Para el modelo inicial, se considera crear:

- 2 capas de convolución para abstraer la informacián de las imágenes, una de 32 neuronas y otra de 64 neuronas.
- Una capa de Dropout con probabilidad de 25%. Estas son capas diseñadas para desestimar aleatoriamente la salida de las convoluciones, reduciendo así un posible overfit, como veremos más adelante.
- Una capa oculta de procesamiento de 128 neuronas.
- Una segunda capa de Dropout con probabilidad de 25%.
- Una capa final con las 10 categorias esperadas.
- ADAM com función de optimización y categorical_crossentropy como función de pérdida.

Como sabemos exactamente cuales son los outputs esperados, esta solución se plantea como un modelo de aprendizaje supervisado.

```
In [ ]: from keras.models import Sequential
        from keras.layers import Dense, Dropout, Flatten, Conv2D, MaxPooling2D
        # Create layers as explained before
        model = Sequential()
        model.add(Conv2D(32, kernel_size=(3, 3),
             activation='relu',
             input_shape=(28, 28, 1)))
        model.add(Conv2D(64, (3, 3), activation='relu'))
        model.add(MaxPooling2D(pool_size=(2, 2)))
        model.add(Dropout(0.25))
        model.add(Flatten())
        model.add(Dense(128, activation='relu'))
        model.add(Dropout(0.5))
        model.add(Dense(10, activation='softmax'))
        # Compile the model using adam as optimizer and categorical crossentropy as the
        model.compile(loss=keras.losses.categorical crossentropy,
                      optimizer='adam',
                      metrics=['accuracy'])
```

Entrenamiento del modelo

Para entrenar el modelo, hacemos 20 corridas de 128 datos por cada corrida. Esto con el fin de ajustar los parámetros al final de cada corrida, haciendo backpropagation.

```
score = model.evaluate(x_test, y_test, verbose=0)
print('Test loss:', score[0])
print('Test accuracy:', score[1])
model.save("src/models/og_model.h5")
```

```
Epoch 1/20
acy: 0.9261 - val_loss: 0.0511 - val_accuracy: 0.9839
Epoch 2/20
y: 0.9747 - val_loss: 0.0395 - val_accuracy: 0.9876
Epoch 3/20
y: 0.9809 - val_loss: 0.0312 - val_accuracy: 0.9901
Epoch 4/20
y: 0.9846 - val loss: 0.0293 - val accuracy: 0.9898
cy: 0.9863 - val_loss: 0.0283 - val_accuracy: 0.9909
Epoch 6/20
y: 0.9882 - val loss: 0.0258 - val accuracy: 0.9914
Epoch 7/20
cy: 0.9888 - val_loss: 0.0264 - val_accuracy: 0.9912
Epoch 8/20
cy: 0.9906 - val_loss: 0.0269 - val_accuracy: 0.9907
Epoch 9/20
469/469 [============ - 4s 9ms/step - loss: 0.0290 - accurac
y: 0.9907 - val_loss: 0.0268 - val_accuracy: 0.9919
Epoch 10/20
y: 0.9917 - val loss: 0.0253 - val accuracy: 0.9926
Epoch 11/20
469/469 [=============] - 4s 9ms/step - loss: 0.0225 - accurac
y: 0.9925 - val_loss: 0.0265 - val_accuracy: 0.9922
Epoch 12/20
cy: 0.9930 - val_loss: 0.0257 - val_accuracy: 0.9922
Epoch 13/20
y: 0.9933 - val_loss: 0.0263 - val_accuracy: 0.9915
Epoch 14/20
y: 0.9936 - val loss: 0.0261 - val accuracy: 0.9925
Epoch 15/20
469/469 [============= - 5s 10ms/step - loss: 0.0191 - accura
cy: 0.9936 - val_loss: 0.0307 - val_accuracy: 0.9912
Epoch 16/20
cy: 0.9947 - val loss: 0.0275 - val accuracy: 0.9922
Epoch 17/20
cy: 0.9947 - val_loss: 0.0295 - val_accuracy: 0.9922
Epoch 18/20
y: 0.9952 - val_loss: 0.0283 - val_accuracy: 0.9929
Epoch 19/20
469/469 [=============] - 4s 9ms/step - loss: 0.0160 - accurac
y: 0.9946 - val_loss: 0.0326 - val_accuracy: 0.9925
Epoch 20/20
y: 0.9954 - val_loss: 0.0293 - val_accuracy: 0.9931
```

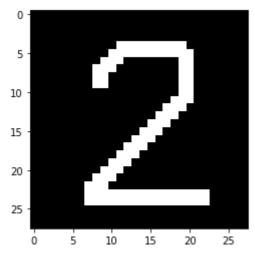
Test loss: 0.029333407059311867 Test accuracy: 0.9930999875068665

```
In [ ]: original_model = keras.models.load_model('src/models/og_model.h5')
```

A continuación, una prueba sobre un dato aislado:

```
import imageio

# Import and process the image
im = imageio.imread("img/2.png")
plt.imshow(im, cmap = plt.get_cmap('gray'))
plt.show()
gray = np.dot(im[...,:3], [0.299, 0.587, 0.114])
gray = gray.reshape(1, 28, 28, 1)
gray /= 255
```



Como vemos, el modelo predice correctamente sobre la imagen suministrada.

Problemas de Overfitting

Haciendo un análisis sobre el porcentaje de error del modelo anterior, se puede ver lo siguiente:

```
y-axis

"""

metric = history.history[metric_name]

val_metric = history.history['val_' + metric_name]

e = range(1, 20 + 1)

plt.plot(e, metric, label='Entrenamiento ' + metric_name)

plt.plot(e, val_metric, label='Validación ' + metric_name)

plt.xlabel('Epoch')

plt.ylabel(metric_name)

plt.title('Comparación ' + metric_name + ' de entrenamiento y validación par

plt.legend()

plt.show()
```

```
In [ ]: eval_metric(original_model, og_model_hist, 'loss', 'Original')
```



El modelo original presenta sintomas de 'overfitting'. Esto es, cuando el modelo queda sobre-entrenado sobre un dataset, tanto que es incapaz de reconocer digitos de manera generalizada. Esto se puede detectar encontrando que a medida que se entrena el modelo, el loss (porcentaje de error) sobre el dataset de entreno baja, mientras que el loss sobre el dataset de validación se mantiene o sube. Para la primera implementación del modelo, se implementan 'Dropout layers'; sin embargo, parece no ser suficiente para resolver el problema. Aunque no es muy grave, se puede ver como el loss sobre el set de validación deja de disminuir en el octavo entrenamiento, y luego sube. Para atacar este problema, se plantean algunas estrategias:

1. Reducir el número de neuronas de la capa de segunda convolucion de 64 a 32, y de la capa oculta de 128 a 64.

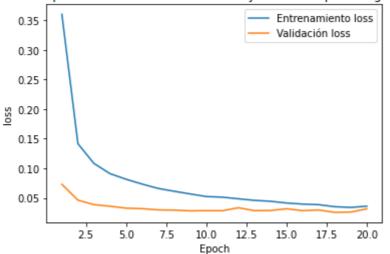
Asi se reduce la capacidad de la red y se obliga a aprender los patrones que importan o que minimizan la pérdida.

```
model_1.add(Dropout(0.25))
        model_1.add(Flatten())
        model_1.add(Dense(64, activation='relu'))
                                                     ## 128 ->64
        model_1.add(Dropout(0.5))
        model_1.add(Dense(10, activation='softmax'))
        # Compile the model_1 using adam as optimizer and categorical_crossentropy as th
        model_1.compile(loss=keras.losses.categorical_crossentropy,
                      optimizer='adam',
                      metrics=['accuracy'])
In [ ]: batch_size = 128
        epochs = 20
        small_model_hist = model_1.fit(x_train, y_train,
                  batch_size=batch_size,
                  epochs=epochs,
                  verbose=1,
                  validation_data=(x_test, y_test))
        score = model_1.evaluate(x_test, y_test, verbose=0)
        print('Test loss:', score[0])
        print('Test accuracy:', score[1])
        model_1.save("src/models/small_model.h5")
        eval_metric(model_1, small_model_hist, 'loss', 'Original')
```

```
Epoch 1/20
y: 0.8884 - val_loss: 0.0731 - val_accuracy: 0.9745
Epoch 2/20
y: 0.9584 - val_loss: 0.0464 - val_accuracy: 0.9854
Epoch 3/20
y: 0.9680 - val_loss: 0.0388 - val_accuracy: 0.9867
Epoch 4/20
y: 0.9725 - val loss: 0.0361 - val accuracy: 0.9885
469/469 [=============] - 3s 7ms/step - loss: 0.0816 - accurac
y: 0.9760 - val_loss: 0.0329 - val_accuracy: 0.9894
Epoch 6/20
y: 0.9779 - val_loss: 0.0320 - val_accuracy: 0.9893
Epoch 7/20
y: 0.9795 - val_loss: 0.0300 - val_accuracy: 0.9897
Epoch 8/20
y: 0.9807 - val_loss: 0.0296 - val_accuracy: 0.9899
Epoch 9/20
y: 0.9825 - val_loss: 0.0283 - val_accuracy: 0.9904
Epoch 10/20
y: 0.9838 - val loss: 0.0287 - val accuracy: 0.9910
Epoch 11/20
469/469 [=============] - 3s 7ms/step - loss: 0.0514 - accurac
y: 0.9843 - val_loss: 0.0286 - val_accuracy: 0.9916
Epoch 12/20
y: 0.9849 - val_loss: 0.0336 - val_accuracy: 0.9897
Epoch 13/20
y: 0.9851 - val_loss: 0.0287 - val_accuracy: 0.9914
Epoch 14/20
y: 0.9852 - val loss: 0.0290 - val accuracy: 0.9916
Epoch 15/20
y: 0.9866 - val_loss: 0.0319 - val_accuracy: 0.9907
Epoch 16/20
y: 0.9871 - val loss: 0.0287 - val accuracy: 0.9925
Epoch 17/20
y: 0.9875 - val_loss: 0.0298 - val_accuracy: 0.9922
Epoch 18/20
y: 0.9880 - val_loss: 0.0259 - val_accuracy: 0.9918
Epoch 19/20
y: 0.9884 - val_loss: 0.0263 - val_accuracy: 0.9925
Epoch 20/20
y: 0.9881 - val_loss: 0.0317 - val_accuracy: 0.9903
```

Test loss: 0.031723055988550186 Test accuracy: 0.9902999997138977





2. Aplicar regularización a la segunda capa de convolución.

Esto añade un coste a la función de pérdida del modelo para los parámetros grandes. Como resultado, se obtiene un modelo más simple que se verá obligado a aprender sólo los patrones relevantes de los datos de entrenamiento. La regularización L2 añade un coste con respecto al valor cuadrado de los parámetros. Esto da lugar a pesos más pequeños para cada neurona.

```
In [ ]: # Create layers as explained before
        model_2 = Sequential()
        model_2.add(Conv2D(32, kernel_size=(3, 3),
             activation='relu',
             input_shape=(28, 28, 1), kernel_regularizer=keras.regularizers.l2(0.01), bi
        model 2.add(Conv2D(64, (3, 3), activation='relu'))
        model_2.add(MaxPooling2D(pool_size=(2, 2)))
        model_2.add(Dropout(0.25))
        model_2.add(Flatten())
        model_2.add(Dense(128, activation='relu'))
        model 2.add(Dropout(0.5))
        model_2.add(Dense(10, activation='softmax'))
        # Compile the model 2 using adam as optimizer and categorical crossentropy as th
        model_2.compile(loss=keras.losses.categorical_crossentropy,
                      optimizer='adam',
                      metrics=['accuracy'])
```

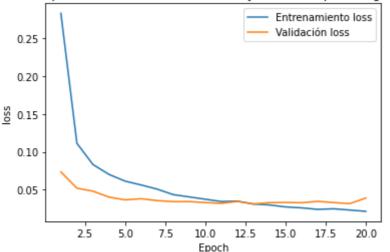
```
score = model_2.evaluate(x_test, y_test, verbose=0)
print('Test loss:', score[0])
print('Test accuracy:', score[1])

model_2.save("src/models/conv_reg_model.h5")
eval_metric(model_2, reg_model_hist, 'loss', 'Original')
```

```
Epoch 1/20
cy: 0.9190 - val_loss: 0.0735 - val_accuracy: 0.9829
Epoch 2/20
cy: 0.9717 - val_loss: 0.0521 - val_accuracy: 0.9879
Epoch 3/20
cy: 0.9779 - val_loss: 0.0481 - val_accuracy: 0.9881
Epoch 4/20
cy: 0.9811 - val loss: 0.0403 - val accuracy: 0.9900
469/469 [=============] - 6s 12ms/step - loss: 0.0614 - accura
cy: 0.9838 - val_loss: 0.0366 - val_accuracy: 0.9897
Epoch 6/20
cy: 0.9847 - val_loss: 0.0381 - val_accuracy: 0.9893
Epoch 7/20
cy: 0.9862 - val_loss: 0.0356 - val_accuracy: 0.9903
Epoch 8/20
469/469 [============= ] - 6s 13ms/step - loss: 0.0436 - accura
cy: 0.9875 - val_loss: 0.0343 - val_accuracy: 0.9908
Epoch 9/20
y: 0.9893 - val_loss: 0.0344 - val_accuracy: 0.9905
Epoch 10/20
y: 0.9896 - val loss: 0.0331 - val accuracy: 0.9921
Epoch 11/20
y: 0.9904 - val_loss: 0.0320 - val_accuracy: 0.9923
Epoch 12/20
cy: 0.9899 - val_loss: 0.0346 - val_accuracy: 0.9904
Epoch 13/20
y: 0.9912 - val_loss: 0.0312 - val_accuracy: 0.9925
Epoch 14/20
y: 0.9914 - val loss: 0.0330 - val accuracy: 0.9916
Epoch 15/20
y: 0.9925 - val_loss: 0.0332 - val_accuracy: 0.9919
Epoch 16/20
y: 0.9928 - val loss: 0.0328 - val accuracy: 0.9912
Epoch 17/20
cy: 0.9930 - val_loss: 0.0347 - val_accuracy: 0.9926
Epoch 18/20
y: 0.9931 - val_loss: 0.0330 - val_accuracy: 0.9914
Epoch 19/20
cy: 0.9934 - val_loss: 0.0317 - val_accuracy: 0.9929
Epoch 20/20
cy: 0.9938 - val_loss: 0.0390 - val_accuracy: 0.9914
```

Test loss: 0.03898705914616585 Test accuracy: 0.9914000034332275

Comparación loss de entrenamiento y validación para Original

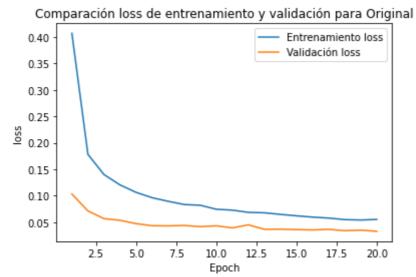


Al combinar las anteriores dos soluciones, se obtiene la solución final:

```
In [ ]: # Create layers as explained before
        model_3 = Sequential()
        model_3.add(Conv2D(32, kernel_size=(3, 3),
             activation='relu',
             input_shape=(28, 28, 1), kernel_regularizer=keras.regularizers.l2(0.01), bi
        model_3.add(Conv2D(32, (3, 3), activation='relu'))
                                                              ## 64 -> 32
        model_3.add(MaxPooling2D(pool_size=(2, 2)))
        model_3.add(Dropout(0.25))
        model_3.add(Flatten())
        model_3.add(Dense(64, activation='relu'))
                                                                    ## 128 -> 64
        model 3.add(Dropout(0.5))
        model_3.add(Dense(10, activation='softmax'))
        # Compile the model_3 using adam as optimizer and categorical_crossentropy as th
        model_3.compile(loss=keras.losses.categorical_crossentropy,
                      optimizer='adam',
                      metrics=['accuracy'])
In [ ]: batch_size = 128
        epochs = 20
        small_conv_reg_hist = model_3.fit(x_train, y_train,
```

```
Epoch 1/20
y: 0.8810 - val_loss: 0.1034 - val_accuracy: 0.9716
Epoch 2/20
y: 0.9521 - val_loss: 0.0714 - val_accuracy: 0.9822
Epoch 3/20
y: 0.9621 - val_loss: 0.0569 - val_accuracy: 0.9849
Epoch 4/20
y: 0.9678 - val loss: 0.0537 - val accuracy: 0.9857
Epoch 5/20
y: 0.9711 - val_loss: 0.0474 - val_accuracy: 0.9875
Epoch 6/20
y: 0.9744 - val_loss: 0.0435 - val_accuracy: 0.9886
Epoch 7/20
y: 0.9754 - val_loss: 0.0432 - val_accuracy: 0.9888
Epoch 8/20
y: 0.9777 - val_loss: 0.0439 - val_accuracy: 0.9887
Epoch 9/20
y: 0.9770 - val_loss: 0.0417 - val_accuracy: 0.9890
Epoch 10/20
y: 0.9786 - val loss: 0.0433 - val accuracy: 0.9883
Epoch 11/20
y: 0.9794 - val_loss: 0.0394 - val_accuracy: 0.9900
Epoch 12/20
y: 0.9810 - val_loss: 0.0451 - val_accuracy: 0.9894
Epoch 13/20
y: 0.9810 - val_loss: 0.0367 - val_accuracy: 0.9899
Epoch 14/20
y: 0.9818 - val loss: 0.0369 - val accuracy: 0.9896
Epoch 15/20
y: 0.9823 - val_loss: 0.0361 - val_accuracy: 0.9900
Epoch 16/20
y: 0.9830 - val loss: 0.0355 - val accuracy: 0.9909
Epoch 17/20
y: 0.9830 - val_loss: 0.0366 - val_accuracy: 0.9899
Epoch 18/20
y: 0.9839 - val_loss: 0.0341 - val_accuracy: 0.9914
Epoch 19/20
y: 0.9845 - val_loss: 0.0352 - val_accuracy: 0.9904
Epoch 20/20
y: 0.9842 - val_loss: 0.0329 - val_accuracy: 0.9914
```

Test loss: 0.032890982925891876 Test accuracy: 0.9914000034332275



Vemos entonces que el modelo no presenta 'overfitting' y está listo para ser usado por el usuario final.